Section 1 : Théorie

Question 1

Partie a) Si A et B sont des événements disjoints et que P(B) > 0, quelle est la valeur de P(A | B) ?

Partie b) Supposons que la fonction de densité de probabilité d'une variable aléatoire X soit définie comme suit :

$$f(x) = \begin{cases} \frac{4}{3}(1 - x^3), & pour\ 0 \leq x \leq 1 \\ 0, & sinon \end{cases}$$

Alors, P (X < 0) = ?

Partie c) Supposons que X soit une variable aléatoire telle que E(X) = μ et Var(X) = σ², et que c soit une constante arbitraire. Lequel des énoncés suivants est vrai ?

A. $E[(X-c)^2] = (\mu - c)^2 + \sigma^2$

B. $E[(X-c)^2] = (\mu - c)^2$

C. $E[(X-c)^2] = (\mu - c)^2 - \sigma^2$

D. $E[(X-c)^2] = (\mu - c)^2 + 2\sigma^2$

E. $E[(X-c)^2] = \mu^2 + c^2 + 2\sigma^2$

F. $E[(X-c)^2] = \mu^2 + c^2 - 2\sigma^2$

Partie d) Supposons que k événements B_1, B_2, …, B_k forment une partition de l'univers S. Pour i = 1, …, k, soit $P(B_i)$ la probabilité a priori de B_i. Considérons un autre événement A tel que P(A) > 0. Soit P (B_i | A) la probabilité a posteriori de B_i sachant que l'événement A s'est produit.

Démontrez que si P (B_1 | A) < P(B_1), alors P(B_i | A) > P(B_i) pour au moins une valeur de i (i = 2, …, k).

Indication : Une ou plusieurs des identités suivantes pourraient vous être utiles :

$$P(B_i \mid A)P(A) = P(B_i \wedge A), \quad \sum_{i=1}^{k} P(B_i) = 1, \quad \sum_{i=1}^{k} P(B_i \mid A) = 1$$

$$P(B_i \wedge A) + P(B_i \wedge \neg A) = P(B_i), \quad \sum_{i=1}^{k} P(B_i \wedge A) = P(A)$$

Question 2

Partie a) Supposons qu'il existe c classes w_1, …, w_c, et un vecteur de caractéristiques x. Donnez la règle de décision de Bayes pour la classification en fonction des probabilités a priori des classes et des densités de probabilité de x conditionnelles aux classes.

Partie b) Supposons que nous ayons un problème à deux classes (A, ~A), avec une seule caractéristique binaire (x, ~x). Supposons que la probabilité a priori soit P(A) = 0,33. Étant donné la répartition des observations présentée dans le tableau suivant, utilisez la règle de Bayes pour calculer les probabilités a posteriori des classes.

	A	**~A**
x	248	167
~x	82	503

Question 3

L'objectif de ce problème est de dériver le classificateur bayésien dans le cas d'une loi de Bernoulli multivariée de dimension d. Comme d'habitude, traitez chaque classe séparément, en interprétant P(x | D) comme P(x | D_i, ω_i). Soit la probabilité conditionnelle pour une catégorie donnée définie par

$$P(x \mid \theta) = \prod_{i=1}^{d} \theta_i^{x_i}(1 - \theta_i)^{1-x_i}$$

et soit D = {x_1, …, x_n} un ensemble de n observations tirées indépendamment selon cette densité de probabilité.

Partie a)

Si s = (s_1, …, s_d) est la somme des n observations, montrez que

$$P(D \mid \theta) = \prod_{i=1}^{d} \theta_i^{s_i}(1 - \theta_i)^{n-s_i}$$

Partie b)

En supposant une loi a priori uniforme pour θ et en utilisant l'identité

$$\int_0^1 \theta^m(1 - \theta)^n \, d\theta = \frac{m!\, n!}{(m + n + 1)!}$$

montrez que

$$p(\theta \mid D) = \prod_{i=1}^{d} \frac{(n + 1)!}{s_i!\,(n - s_i)!} \theta_i^{s_i}(1 - \theta_i)^{n-s_i}$$

Partie c)

Tracez cette densité pour le cas d = 1, n = 1 et pour les deux valeurs possibles de s_1 qui en résultent.

Partie d)

Intégrez le produit P(x | θ)p(θ | D) par rapport à θ pour obtenir la probabilité conditionnelle recherchée

$$P(x \mid D) = \prod_{i=1}^{d} \left(\frac{s_i + 1}{n + 2}\right)^{x_i}\left(1 - \frac{s_i + 1}{n + 2}\right)^{1-x_i}$$

Partie e)

Si l'on envisage d'obtenir P(x | D) en remplaçant θ par une estimation $\hat{\theta}$ dans P(x | θ), quelle est l'estimation bayésienne effective de θ ?

Question 4

Supposons que nous disposions du jeu de données suivant, où A, B et C sont des variables aléatoires binaires d'entrée et où y est une sortie binaire dont nous souhaitons prédire la valeur.

A	B	C	y
0	0	1	0
0	1	0	0
1	1	0	0
0	0	1	1
1	1	1	1
1	0	0	1
1	1	0	1

Partie a)

Quelle valeur de y un classificateur bayésien naïf prédirait-il pour l'entrée suivante : A = 0, B = 0, C = 1 ? Supposez qu'en cas d'égalité, le classificateur choisit toujours de prédire 0 pour y.

Partie b)

Supposons que vous sachiez avec certitude que A, B et C sont des variables aléatoires indépendantes. Dans ce cas, est-il possible qu'un autre classificateur (par exemple, un arbre de décision ou un réseau de neurones) fasse mieux qu'un classificateur bayésien naïf ? (Le jeu de données n'est pas pertinent pour cette question.)

Section 2 : Programmation

Question 5 - Prédiction de la récidive du cancer du sein

Construisez une chaîne de traitement pour la classification avec scikit-learn à l'aide du jeu de données Breast Cancer de l'UCI (jeu de données 14) : 286 observations, neuf variables prédictives et deux classes déséquilibrées. Prédisez la classe recurrence-events ou no-recurrence-events. Utilisez le jeu de données original sur la récidive, composé de variables catégorielles, et non sklearn.datasets.load_breast_cancer().

Jeu de données et téléchargement : UCI Breast Cancer (https://archive.ics.uci.edu/dataset/14/breast%2Bcancer)

Téléchargez breast-cancer.data et utilisez breast-cancer.names pour obtenir les noms des colonnes et les définitions des catégories. Le fichier de données ne comporte pas d'en-tête ; sa première colonne est la variable cible. Traitez les neuf variables prédictives comme des variables catégorielles, y compris les libellés d'intervalles et le degré de malignité.

A) Examiner et partitionner les données

Chargez les données avec pandas. Interprétez ? comme une valeur manquante, indiquez le nombre de valeurs manquantes par caractéristique ainsi que les effectifs des classes, puis séparez les variables prédictives de la variable cible. Effectuez une partition stratifiée en ensembles d'entraînement et de test selon un rapport de 80/20, avec random_state=42, avant d'ajuster toute étape de prétraitement.

B) Prétraiter les données et entraîner le modèle

Construisez un Pipeline qui impute les valeurs manquantes à l'aide du mode de chaque colonne de l'ensemble d'entraînement, encode les catégories sous forme d'identifiants entiers non négatifs et ajuste CategoricalNB(alpha=1.0). Utilisez SimpleImputer et OrdinalEncoder. Assurez-vous que les catégories valides absentes de l'ensemble d'entraînement puissent tout de même être traitées lors de la prédiction. N'ajustez pas l'imputeur et ne déterminez pas les catégories à partir de l'ensemble de test.

C) Évaluer

Sur l'ensemble de test réservé à l'évaluation, indiquez l'exactitude (accuracy), l'exactitude équilibrée (balanced accuracy), la précision, le rappel et le score F1 pour la classe de récidive, ainsi qu'une matrice de confusion avec les libellés des classes.

Comparez l'exactitude et l'exactitude équilibrée à celles de DummyClassifier(strategy="most_frequent") ajusté sur l'ensemble d'entraînement. Conservez la même partition des données pour les deux modèles.

D) Expliquer

En 100 à 150 mots, justifiez l'utilisation de CategoricalNB pour ces caractéristiques, expliquez comment votre prétraitement évite la fuite de données et discutez des raisons pour lesquelles l'exactitude seule peut être trompeuse. Interprétez le rappel de la classe de récidive et décrivez une limite de l'hypothèse d'indépendance du modèle bayésien naïf.

Indication pour l'encodage : Vous pouvez définir l'ensemble complet des catégories à partir des métadonnées publiées par l'UCI à l'aide de OrdinalEncoder(categories=...). Définissez CategoricalNB(min_categories=...) en fonction du nombre de catégories de chaque caractéristique, afin que des entrées de probabilité soient également allouées aux catégories absentes de l'ensemble d'entraînement. Veillez à la cohérence des types des catégories ; les codes négatifs ne sont pas valides pour CategoricalNB.

Travail à remettre :

1) Créez un seul fichier PDF (uniquement un fichier PDF), contenant les parties théorique et de programmation.
2) Vous devez nommer votre fichier selon la convention suivante :
   A#_studentID, où # est le numéro du devoir et studentID est votre numéro d'étudiant.
3) Les devoirs doivent être remis dans la section des devoirs (Léa) au plus tard le 25 octobre 2026 à 23 h 55.